Plan de Asignatura

Departamento de Estadística

Asignatura: Minería de Datos
Código: 2016325
Créditos:
Horario: Martes y Jueves de 9:00 a 11:00
Docente: Andrés Felipe Flórez Rivera
Correo: afflorezr@unal.edu.co
Horario de atención: Viernes 10:00-12:00

Descripción del curso

El curso se centra en el proceso de Descubrimiento de Conocimiento en Bases de Datos (KDD), integrando técnicas estadísticas y algoritmos de aprendizaje automático para identificar patrones útiles en los datos. Se aborda el ciclo completo de análisis: adquisición, preparación, modelamiento, evaluación e interpretación, incluyendo fuentes modernas de datos como la web y bases de datos.

Objetivo de formación

Capacitar al estudiante para transformar datos en conocimiento útil mediante:

- Adquisición de datos desde diversas fuentes.
- Procesamiento y análisis estadístico.
- Aplicación de modelos predictivos y descriptivos

Objetivos pedagógicos

- Ejecutar las fases del proceso KDD: adquisición, preparación, modelado e interpretación de datos.
- Obtener datos desde diversas fuentes, incluyendo archivos, web y bases de datos.
- Limpiar, transformar y reducir datos para su análisis.
- Implementar modelos de regresión y clasificación.

- Aplicar técnicas de aprendizaje no supervisado para el descubrimiento de patrones.
- Evaluar modelos mediante métricas estadísticas adecuadas.
- Interpretar los resultados obtenidos en contextos reales.
- Comunicar hallazgos de manera clara y estructurada.

Metodología

El curso se desarrollará mediante clases presenciales. Se combinarán clases magistrales con sesiones prácticas en R y Python, orientadas a la aplicación de los conceptos en datos reales. Se promoverá la lectura previa de los temas y la participación activa de los estudiantes. Se realizarán talleres prácticos para afianzar los conocimientos y desarrollar habilidades de análisis e interpretación de resultados.

Evaluación

Los talleres parciales y el trabajo final incluirán componentes tanto conceptuales como prácticos, y estarán fundamentados en los contenidos y ejercicios desarrollados durante el curso.

Para cada taller parcial, el estudiante dispondrá de un plazo de 15 días calendario a partir de la fecha de publicación del enunciado para su desarrollo y entrega.

Cada taller deberá ser presentado en formato Markdown, utilizando R Markdown (.Rmd) o Quarto (.qmd). La entrega debe incluir:

- El archivo fuente (.Rmd o .qmd).
- El documento renderizado en formato HTML.
- Un análisis claro de resultados y conclusiones.
- El código utilizado para obtener dichos resultados.

Las entregas realizadas fuera de la fecha establecida tendrán una penalización de 0.5 puntos sobre la calificación máxima por cada día de retraso, aplicándose de manera acumulativa. Después de 10 días calendario de retraso, no se aceptarán entregas.

Evaluación	**Porcentaje**	**Fecha**
Primer taller parcial	25 %	07-05-2026
Segundo taller parcial	25 %	04-04-2026
Tercer taller parcial	25 %	02-07-2026
Taller final	25 %	23-07-2026

Contenido

1. Introducción y Proceso KDD (Semanas 1–2, 4 clases)
   - Concepto de Minería de Datos y KDD.
   - Relación con la Ciencia de Datos.
   - Aprendizaje estadístico vs aprendizaje automático.
   - Fases del proceso KDD.
   - Diferencias con OLAP.
2. Adquisición de Datos (Semana 3, 2 clases)
   - Fuentes de datos:
     - Archivos (CSV, Excel)
     - Web
     - Bases de datos
   - Introducción a la adquisición de datos desde la web (web scraping básico)
   - Introducción a SQL:
     - SELECT
     - WHERE
     - GROUP BY
   - Fuentes de datos abiertos (por ejemplo, DANE, datos.gov.co)
3. Tipos de Datos y Estructuras (Semana 4, 2 clases)
   - Tipos de variables.
   - Estructura de datos.
   - Datos estructurados y no estructurados.
   - Problemas de alta dimensionalidad.
4. Preparación y Gestión de Datos (Semanas 5–6, 4 clases)
   - Limpieza de datos.
   - Transformación y normalización.
   - Manejo de valores faltantes.
   - Integración de fuentes.
5. Análisis Exploratorio de Datos (Semanas 7–8, 4 clases)

- Tablas y gráficos.
- Distribuciones de frecuencia.
- Medidas estadísticas.
- Visualización de datos.

6. Análisis de Relaciones entre Variables (Semana 9, 2 clases)
   - Correlación (Pearson, Spearman).
   - Tablas de contingencia.
   - Medidas de asociación.
   - Interpretación de relaciones.
7. Modelos de Regresión (Semanas 10–11, 4 clases)
   - Regresión lineal simple y múltiple.
   - Regresión logística.
   - Interpretación de coeficientes.
8. Evaluación de Modelos Predictivos (Semana 12, 2 clases)
   - Error de entrenamiento y validación.
   - MAE, MSE, RMSE.
   - MAPE (Mean Absolute Percentage Error).
   - Validación cruzada.
   - Sesgo vs varianza.
   - Curva ROC y AUC.
9. Aprendizaje Supervisado I (Semanas 13, 2 clases)
   - Árboles de decisión.
   - k-NN.
   - Clasificación logística.
10. Aprendizaje Supervisado II (Semana 14, 2 clases)
    - Regularización de modelos:
      - Ridge
      - Lasso
    - Problema de sobreajuste (overfitting)

- Métodos de ensamble (introducción conceptual):
  - Bagging
  - Random Forest
  - Boosting

11. Aprendizaje No Supervisado (Semana 15, 2 clases)
    - Reglas de asociación.
    - K-Means y clustering.
    - DBScan y métodos jerárquicos.
12. Reducción de Dimensionalidad (Semana 16, 2 clases)
    - PCA.
    - Análisis factorial.
    - Datos de alta dimensión.
13. Integración del Proceso KDD (Opcional)
    - Aplicación completa del proceso.
    - Validación de resultados.
    - Comunicación de hallazgos.

Bibliografía

- Han, J., Kamber, M. y Pei, J. *Data Mining: Concepts and Techniques*. Morgan Kaufmann.
- James, G., Witten, D., Hastie, T. y Tibshirani, R. *An Introduction to Statistical Learning*. Springer.
- Tan, P.-N., Steinbach, M. y Kumar, V. *Introduction to Data Mining*. Pearson.
- Murphy, K. *Machine Learning: A Probabilistic Perspective*. MIT Press.
- Hastie, T., Tibshirani, R. y Friedman, J. *The Elements of Statistical Learning*. Springer.
- Géron, A. *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow*. O'Reilly.
- Wickham, H. y Grolemund, G. *R for Data Science*. O'Reilly.

- VanderPlas, J. *Python Data Science Handbook*. O'Reilly.
- Mitchell, R. *Web Scraping with Python*. O'Reilly.
- Beaulieu, A. *Learning SQL*. O'Reilly.